Laporan Praktikum: Pengenalan Vowel Bahasa Indonesia dengan DTW dan Model Gaussian

IF4071 Pemrosesan Ucapan



Disusun oleh:

13523018 - Raka Daffa Iftikhaar
13523049 - Muhammad Fithra Rizki
13523055 - Muhammad Timur Kanigara
13523062 - Aliya Husna Fayyaza
13523113 - Kefas Kurnia Jonathan
13523118 - Farrel Athalla Putra

Institut Teknologi Bandung

Jl. Ganesa No. 10, Lebak Siliwangi, Kecamatan Coblong, Kota Bandung, Jawa Barat 40132

1. Identitas Kelompok

Laporan ini disusun untuk praktikum IF4071 Pemrosesan Ucapan. Praktikum ini membangun dan membandingkan dua sistem pengenal *vowel* Bahasa Indonesia /a/, /i/, /u/, /e/, dan /o/, yaitu sistem berbasis *Dynamic Time Warping* (DTW) dengan *averaged template* dan sistem berbasis Model Gaussian. Kelompok kami beranggotakan enam orang, dan setiap anggota diberi kode *speaker* S1 sampai S6 yang dipakai pada nama *file* dan tabel hasil.

No	Nama	NIM	Kode Speaker
1	Aliya Husna Fayyaza	13523062	S1
2	Farrel Athalla Putra	13523118	S2
3	Muhammad Fithra Rizki	13523049	S3
4	Kefas Kurnia Jonathan	13523113	S4
5	Raka Daffa Iftikhaar	13523018	S5
6	Muhammad Timur Kanigara	13523055	S6

Tabel 1. Anggota kelompok dan kode speaker

2. Link Program

Seluruh *source code* tersedia pada *repository* GitHub berikut.

https://github.com/aliyahusnaf/Praktikum-1-IF4071-Speech-Processing

Kode utama berada di folder src/, yaitu *preprocessing* dan *data loading* (preprocessing.py, prepare_dataset.py, prepare_open_set.py, data_loader.py), ekstraksi MFCC 39 dimensi (mfcc.py), Sistem 1 DTW (dtw.py), Sistem 2 Model Gaussian (gaussian.py), serta *recognition* dan perhitungan akurasi (evaluation.py dan compare.py). Hasil prediksi dan akurasi setiap sistem disimpan di folder outputs/.

3. Link Data

Dataset disimpan di *repository* yang sama pada folder data/, sehingga dapat diakses melalui tautan berikut.

https://github.com/aliyahusnaf/Praktikum-1-IF4071-Speech-Processing/tree/main/data

Setiap anggota merekam lima *vowel* sebanyak dua kali. Rekaman pertama dipakai sebagai data *template*, sedangkan rekaman kedua dipakai sebagai data uji *closed speakers*. Spesifikasi mengasumsikan lima anggota, tetapi karena kelompok kami berisi enam orang, setiap *template vowel* dibentuk dari enam rekaman. Nama *file* mengikuti pola S1_a1.wav, yaitu *speaker* S1, *vowel* a, rekaman ke-1. Struktur dataset dapat dilihat pada tabel berikut.

Folder	Isi	Jumlah file
data/raw/<nama>/	Rekaman asli enam anggota (WAV dan M4A)	60
data/processed/template/	Rekaman ke-1 dari S1 sampai S6, dipakai untuk membentuk template DTW dan Model Gaussian, sekaligus menjadi data uji closed recordings	30
data/processed/test/closed/	Rekaman ke-2 dari S1 sampai S6, data uji closed speakers	30
data/raw/open/A, E, I, O, U/	Rekaman asli dari kelompok lain	80
data/processed/test/open/	Data uji open speakers setelah preprocessing, satu rekaman per vowel	80

Tabel 2. Struktur dataset

Data *open speakers* berasal dari 4 kelompok lain dengan total 16 *speaker*. Setiap kelompok memakai pola nama *file* yang berbeda, sehingga semua nama diseragamkan menjadi G<kelompok>S<speaker>_<vowel>.wav, misalnya G04S03_a.wav untuk *speaker* S03 dari kelompok 4. Semua rekaman, baik *closed* maupun *open*, dikonversi ke WAV 16 kHz mono 16-bit, dihapus DC *offset*-nya, dan dipotong jeda awal dan akhirnya. Rincian sumber data *open* dapat dilihat pada tabel berikut.

Kode	Pola nama file asli	Speaker	Jumlah file
G03	Kel3_Sxx_V.wav	S01, S02, S03, S05	20
G04	G04_Sxx_V.wav	S03, S04	10
G07	G07_Sxx_V.wav	S01, S02, S03, S04, S05	25
G09	G09_Sxx_V01.wav	S01, S02, S03, S04, S05	25
Total		**16**	**80**

Tabel 3. Sumber data open speakers

4. Hasil Eksperimen

Kedua sistem memakai fitur MFCC 39 dimensi dari python_speech_features, yaitu 13 koefisien statis (log energi menggantikan c0) ditambah *delta* dan *delta-delta*, dengan *frame* 25 ms dan *hop* 10 ms. Sistem 1 membandingkan *input* dengan satu *averaged template* per *vowel* menggunakan DTW berjarak Euclidean, lalu memilih *template* dengan *cost* terkecil. *Template* dibentuk dari *medoid* enam rekaman *template*, yaitu rekaman yang paling dekat dengan rekaman lainnya, kemudian semua rekaman disejajarkan ke *medoid* dan dirata-rata sebanyak 5 iterasi. Sistem 2 memodelkan setiap *vowel* dengan satu Gaussian (*mean* dan

full covariance 39 × 39) dari seluruh *frame template vowel* tersebut, lalu memilih *vowel* dengan rata-rata *negative log-likelihood* (NLL) terkecil. Kedua sistem tidak memakai normalisasi fitur.

4.1 Ringkasan Akurasi per Skenario

Sistem	Closed Recording	Closed Speakers	Open Speakers	Rata-rata
DTW Template	96,67% (29/30)	96,67% (29/30)	82,50% (66/80)	91,94%
Model Gaussian	100,00% (30/30)	93,33% (28/30)	68,75% (55/80)	87,36%

Tabel 4. Ringkasan akurasi per skenario

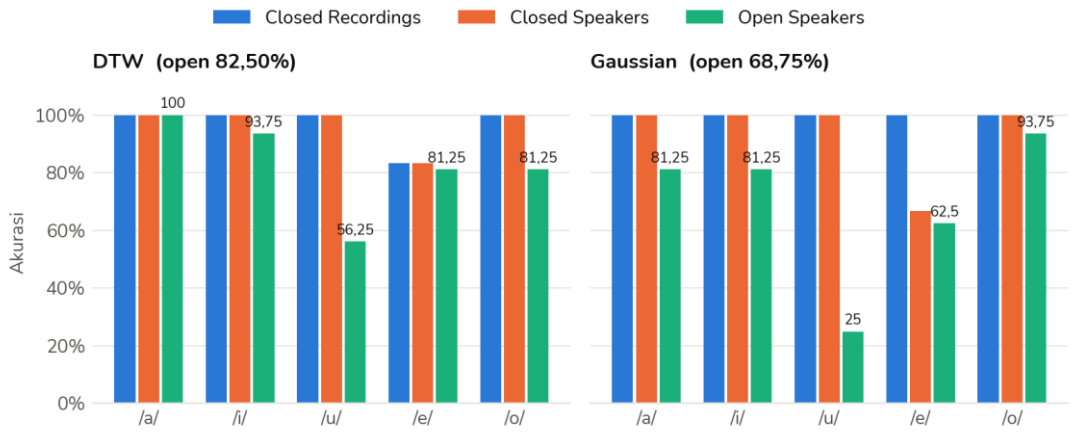
Dapat dilihat bahwa DTW memperoleh rata-rata akurasi lebih tinggi, yaitu 91,94% dibanding 87,36% pada Gaussian. Gaussian unggul pada *closed recordings* (100,00% dibanding 96,67%), tetapi DTW lebih baik pada *closed speakers* (96,67% dibanding 93,33%) dan terutama pada *open speakers* (82,50% dibanding 68,75%). Dari *closed speakers* ke *open speakers*, akurasi DTW turun 14,17 poin, sedangkan Gaussian turun 24,58 poin.

4.2 Akurasi per Vowel

Vowel	DTW Closed Recording	DTW Closed Speakers	DTW Open Speakers	Gaussian Closed Recording	Gaussian Closed Speakers	Gaussian Open
/a/	100,00%	100,00%	100,00%	100,00%	100,00%	81,25%
/i/	100,00%	100,00%	93,75%	100,00%	100,00%	81,25%
/u/	100,00%	100,00%	56,25%	100,00%	100,00%	25,00%
/e/	83,33%	83,33%	81,25%	100,00%	66,67%	62,50%
/o/	100,00%	100,00%	81,25%	100,00%	100,00%	93,75%
Average Accuracy	**96,67%**	**96,67%**	**82,50%**	**100,00%**	**93,33%**	**68,75%**

Tabel 5. Akurasi untuk setiap vowel (Tabel 1 pada spesifikasi)

Setiap *vowel* memiliki 6 data uji pada skenario *closed* dan 16 data uji pada skenario *open*, sehingga *Average Accuracy* sama dengan akurasi total skenario tersebut. Berdasarkan pengujian, satu-satunya *vowel* yang tidak 100% pada skenario *closed* adalah /e/. Pada *open speakers*, DTW lebih tinggi pada empat dari lima *vowel*, yaitu /a/ (100,00% dibanding 81,25%), /i/ (93,75% dibanding 81,25%), /u/ (56,25% dibanding 25,00%), dan /e/ (81,25% dibanding 62,50%). Gaussian hanya unggul pada /o/ (93,75% dibanding 81,25%), dan /u/ menjadi *vowel* tersulit bagi kedua sistem.



Gambar 1. Akurasi per vowel untuk setiap skenario. Angka di atas batang adalah akurasi open speakers

4.3 Closed Experiments per Speaker

Speakers	DTW Closed Recording	DTW Closed Speakers	Gaussian Closed Recordings	Gaussian Closed Speakers	Average
Closed 1 (S1, Aliya)	100,00%	100,00%	100,00%	80,00%	95,00%
Closed 2 (S2, Farrel)	100,00%	100,00%	100,00%	100,00%	100,00%
Closed 3 (S3, Fithra)	100,00%	100,00%	100,00%	100,00%	100,00%
Closed 4 (S4, Kefas)	100,00%	100,00%	100,00%	100,00%	100,00%
Closed 5 (S5, Rakdaf)	100,00%	100,00%	100,00%	100,00%	100,00%
Closed 6 (S6, Timur)	80,00%	80,00%	100,00%	80,00%	85,00%
Average	**96,67%**	**96,67%**	**100,00%**	**93,33%**	**96,67%**

Tabel 6. Closed experiments per speaker (Tabel 2 pada spesifikasi)

Setiap *speaker* memiliki 5 data uji per skenario, sehingga satu kesalahan bernilai 20 poin. Dapat dilihat bahwa S2 sampai S5 dikenali 100% oleh kedua sistem. Kesalahan DTW adalah S6_e1 → /i/ pada *closed recordings* dan S6_e2 → /i/ pada *closed speakers*, sedangkan kesalahan Gaussian hanya ada pada *closed speakers*, yaitu S1_e2 → /o/, S6_e2 → /i/. Semua kesalahan *closed* terjadi pada *vowel* /e/, dan rata-rata kedua skenario *closed* sama untuk kedua sistem, yaitu 96,67%.

4.4 Open Experiments per Speaker

Speakers	DTW Open	Gaussian Open	Average
G03S01	80,00%	60,00%	70,00%
G03S02	100,00%	80,00%	90,00%
G03S03	80,00%	60,00%	70,00%
G03S05	60,00%	80,00%	70,00%
G04S03	80,00%	60,00%	70,00%
G04S04	40,00%	40,00%	40,00%
G07S01	80,00%	60,00%	70,00%
G07S02	60,00%	60,00%	60,00%
G07S03	100,00%	60,00%	80,00%

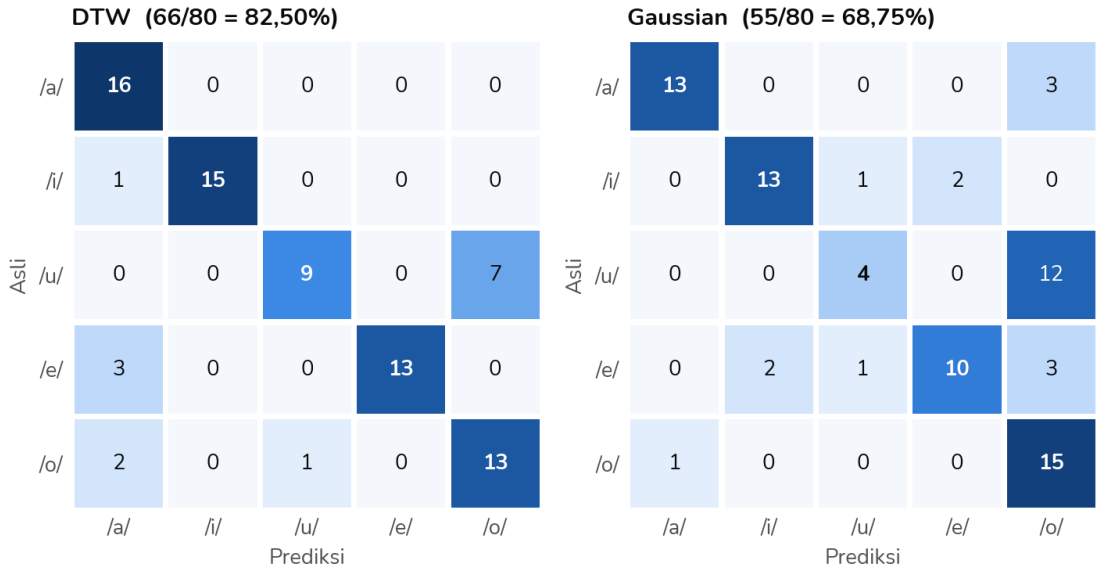
Speakers	DTW Open	Gaussian Open	Average
G07S04	80,00%	80,00%	80,00%
G07S05	80,00%	80,00%	80,00%
G09S01	100,00%	100,00%	100,00%
G09S02	100,00%	60,00%	80,00%
G09S03	100,00%	80,00%	90,00%
G09S04	100,00%	60,00%	80,00%
G09S05	80,00%	80,00%	80,00%
Average	**82,50%**	**68,75%**	**75,62%**

Tabel 7. Open experiments per speaker (Tabel 3 pada spesifikasi)

Kolom *Average* adalah rata-rata DTW *Open* dan Gaussian *Open*. Dari 16 *speaker open*, DTW lebih tinggi pada 9 *speaker*, sama pada 6 *speaker*, dan lebih rendah pada 1 *speaker*. DTW mencapai 100% pada 6 *speaker*, sedangkan Gaussian hanya pada 1 *speaker*. *Speaker* tersulit bagi kedua sistem adalah G04S04 dengan akurasi 40,00%. Jika dikelompokkan per kelompok asal, DTW tetap lebih tinggi pada keempat kelompok, yaitu G03 (80,00% dibanding 70,00%), G04 (60,00% dibanding 50,00%), G07 (80,00% dibanding 68,00%), dan G09 (96,00% dibanding 76,00%), sehingga keunggulannya tidak bergantung pada kondisi rekaman satu kelompok saja.

4.5 Confusion Matrix

Confusion matrix open speakers untuk kedua sistem dapat dilihat pada Gambar 2. Baris adalah label asli, kolom adalah hasil prediksi, dan warna sel menunjukkan proporsi terhadap jumlah data pada baris tersebut.



Gambar 2. Confusion matrix open speakers untuk DTW (kiri) dan Gaussian (kanan)

Berdasarkan Gambar 2, kesalahan terbanyak pada kedua sistem sama, yaitu /u/ dikenali sebagai /o/, dengan 7 dari 16 *file* pada DTW dan 12 dari 16 *file* pada Gaussian.

Arah kesalahan lainnya berbeda. Pada DTW, 6 dari 14 kesalahan jatuh ke /a/, misalnya /e/ → /a/ sebanyak 3 dan /o/ → /a/ sebanyak 2. Pada Gaussian, 18 dari 25 kesalahan jatuh ke /o/, yaitu dari /u/, /a/ (3), dan /e/ (3). Pada skenario *closed*, *confusion matrix* kedua sistem hampir diagonal sempurna, dan satu-satunya baris yang memiliki kesalahan adalah /e/, yang dikenali sebagai /i/ (DTW dan Gaussian) atau /o/ (Gaussian).

4.6 Eksperimen Tambahan

Selain konfigurasi utama, kami juga mencoba CMVN (*cepstral mean and variance normalization*) per *speaker*, variasi jumlah iterasi *averaging* pada DTW, serta *diagonal covariance* pada Gaussian. Secara singkat, *averaged template* menaikkan akurasi *open* DTW dari 71,25% (*medoid* tanpa *averaging*) menjadi 82,50%. CMVN dengan *diagonal covariance* menaikkan akurasi *open* Gaussian menjadi 92,50%, sedangkan pada DTW, CMVN justru menurunkan akurasi *open* menjadi 77,50%. Karena konfigurasi ini dipilih tanpa data validasi terpisah, hasilnya tidak kami pakai sebagai hasil utama.

5. Hasil Analisis

5.1 Akurasi Closed Scenario

Pada *closed recordings*, Gaussian mencapai 100,00%, sedangkan DTW 96,67%. Hal ini masuk akal karena *mean* dan *covariance* Gaussian dihitung dari *frame* yang persis sama dengan data uji, sedangkan DTW membandingkan data uji dengan *template* hasil rata-rata enam *speaker*, bukan dengan rekamannya sendiri. Akibatnya, /e/ milik S6 sudah tidak terwakili dengan baik oleh *template* /e/ dan lebih dekat ke *template* /i/. Pada *closed speakers*, urutannya berbalik. DTW tetap 96,67%, sedangkan Gaussian turun menjadi 93,33%. Kedua sistem sama-sama gagal pada S6_e2, sehingga menurut kami penyebabnya lebih banyak berasal dari cara S6 mengucapkan /e/. Secara keseluruhan, kedua sistem setara pada *closed scenario*, tetapi hanya Gaussian yang turun dari *closed recordings* ke *closed speakers* (6,67 poin). Hal ini menandakan model Gaussian sudah terlalu menyesuaikan diri dengan rekaman latih, bahkan untuk *speaker* yang sama.

5.2 Akurasi Open Scenario

Pada *open speakers*, DTW mencapai 82,50% dan Gaussian 68,75%, dengan selisih 13,75 poin. Jika dilihat per *file*, 9 *file* salah pada kedua sistem, 16 *file* hanya salah pada Gaussian, dan hanya 5 *file* yang salah pada DTW saja. Penurunan juga terlihat dari skor masing-masing sistem. Selisih skor kelas benar ke kelas pesaing terdekat pada DTW turun dari 2,73 (*closed recordings*) menjadi 1,22 (*open*), sedangkan pada Gaussian turun dari

28,20 menjadi 5,64. Satuan kedua skor berbeda, tetapi proporsinya dapat dibandingkan. DTW masih menyisakan 45% dari selisih awalnya, sedangkan Gaussian hanya 20%. Artinya, pada *speaker* baru kelas yang benar masih cukup jelas unggul pada DTW, sedangkan pada Gaussian kelas yang benar hanya menang tipis.

5.3 Rata-rata Akurasi

Rata-rata ketiga skenario adalah 91,94% untuk DTW dan 87,36% untuk Gaussian. Karena rata-rata dua skenario *closed* kedua sistem sama, seluruh selisih 4,58 poin ini berasal dari *open speakers*. Rata-rata sederhana memberi bobot yang sama pada setiap skenario, padahal *open speakers* memiliki 80 data uji dan setiap skenario *closed* hanya 30. Jika semua 140 data uji digabung, akurasinya menjadi 88,57% untuk DTW dan 80,71% untuk Gaussian, sehingga selisihnya justru melebar. Menurut analisis kami, untuk menilai kemampuan sistem pada pengguna baru, akurasi *open speakers* lebih representatif dibanding rata-rata yang terangkat oleh dua skenario *closed*.

5.4 Pengaruh Perbedaan Speaker

Perbedaan *speaker* adalah penyebab utama turunnya akurasi pada kedua sistem. Bentuk dan panjang saluran suara menentukan letak *formant*, sehingga *vowel* yang sama dari dua orang menghasilkan MFCC yang berbeda. Sebagai indikator kasar, kami memperkirakan *pitch* (F0) median setiap *speaker* dengan autokorelasi. F0 *speaker* latih berada pada rentang 116 sampai 213 Hz, sedangkan 4 *speaker open* berada di atasnya (G04S04 276 Hz, G04S03 229 Hz, G07S02 225 Hz, G03S03 216 Hz). Rata-rata akurasi 4 *speaker* ini adalah 65,00% pada DTW dan 55,00% pada Gaussian, lebih rendah dari 12 *speaker* lainnya (88,33% dan 73,33%). *Speaker* dengan F0 tertinggi, G04S04, mendapat akurasi terendah pada kedua sistem. Hubungan ini tidak sempurna, karena G04S03 masih dikenali 80,00% oleh DTW, dan rekaman G04S03 juga paling pelan (RMS rata-rata 0,027), sehingga kondisi rekaman ikut berpengaruh.

Pengaruh *speaker* juga terlihat pada skenario *closed*. Kesalahan kedua sistem terkumpul pada S6, yaitu /e/ yang dikenali sebagai /i/, sedangkan S2 sampai S5 selalu dikenali dengan benar. Hal ini menunjukkan bahwa cara satu *speaker* mengucapkan *vowel* dapat menyimpang dari rata-rata kelompok, walaupun *speaker* tersebut ikut membentuk *template* dan model. Secara keseluruhan, DTW lebih tahan terhadap perbedaan *speaker*, dengan penurunan dari *closed speakers* ke *open* sebesar 14,17 poin dibanding 24,58 poin pada Gaussian.

5.5 Pengaruh Averaged/Generalized Template

Averaged template pada DTW menggabungkan enam *speaker* menjadi satu *template* per *vowel*, dan pengaruhnya terlihat dari dua sisi. Di satu sisi, *template* tidak lagi identik dengan rekaman mana pun, sehingga *closed recordings* DTW hanya 96,67% dan S6_e1 salah dikenali walaupun rekaman tersebut ikut membentuk *template*. Di sisi lain, karena *template* sudah mewakili rata-rata beberapa orang, akurasi DTW tidak turun sama sekali dari *closed recordings* ke *closed speakers* (keduanya 96,67%), dan penurunannya ke *open speakers* lebih kecil dibanding Gaussian. Jadi, *averaging* mengorbankan sedikit akurasi pada data latih, tetapi membuat *template* lebih umum untuk rekaman dan *speaker* baru.

Model Gaussian juga merupakan generalisasi dari enam *speaker*. *Mean* berperan seperti *template* rata-rata, sedangkan *covariance* menyimpan sebaran variasi yang dianggap wajar. *Full covariance* memiliki 39 + 780 = 819 parameter per *vowel* yang diperkirakan dari 383 sampai 562 *frame*. *Frame* tersebut hanya berasal dari enam rekaman dan sangat mirip satu sama lain, sehingga korelasi yang dipelajari ikut membawa ciri khas *speaker* latih. Hal ini sesuai dengan hasil Gaussian yang sempurna pada *closed recordings*, tetapi paling banyak turun pada *open speakers*. Menurut kami, pada data sekecil ini generalisasi yang lebih sederhana, seperti *averaged template* DTW yang hanya menyimpan rata-rata, justru lebih berguna.

5.6 Kesalahan Pengenalan Vowel

Kesalahan /u/ → /o/ paling dominan pada kedua sistem (7 dari 16 pada DTW dan 12 dari 16 pada Gaussian). *Vowel* /u/ dan /o/ sama-sama *vowel* belakang dengan bibir membulat, dan perbedaannya terutama ada pada tinggi lidah, sehingga selisih spektrumnya mudah tertutup oleh pergeseran *formant* antar *speaker*. Pada Gaussian, masalah ini diperparah oleh model /u/ yang paling sempit, dengan *frame* latih paling sedikit (383) dan log determinan *covariance* terkecil (-90,6, dibanding /o/ -85,1). Model yang sempit memberi penalti besar untuk *frame* yang sedikit bergeser, sehingga /u/ dari *speaker* baru justru mendapat NLL lebih kecil pada model /o/.

Vowel /e/ menjadi satu-satunya sumber kesalahan pada skenario *closed*, dan pada *open* akurasinya 81,25% untuk DTW dan 62,50% untuk Gaussian. *Vowel* /e/ terletak di tengah ruang *vowel*, dan huruf e dalam bahasa Indonesia diucapkan dengan keterbukaan mulut yang berbeda-beda, dari [e] yang dekat ke /i/ sampai [ɛ] yang lebih terbuka dan dekat ke /a/. Hal ini sesuai dengan arah kesalahannya, yaitu /e/ → /i/ pada *closed* dan /e/ → /a/ pada DTW *open*. Selain itu, setiap sistem memiliki satu *vowel* penampung kesalahan, yaitu /a/ pada DTW (6 dari 14 kesalahan) dan /o/ pada Gaussian (18 dari 25 kesalahan).

Akibatnya, akurasi *open* tertinggi juga jatuh pada *vowel* tersebut, yaitu /a/ 100,00% pada DTW dan /o/ 93,75% pada Gaussian, sehingga angka ini sebagian berasal dari kecenderungan sistem memilihnya.

5.7 Mengapa Performa DTW dan Gaussian Berbeda?

Perbedaan performa berasal dari cara masing-masing sistem mengukur kedekatan antara *input* dan model. Berdasarkan hasil di atas, menurut kami terdapat dua penyebab sebagai berikut.

- Bentuk jarak, di mana DTW memakai jarak Euclidean ke *averaged template*, dan karena 97,9% varians fitur ada pada 13 koefisien statis, jaraknya ditentukan oleh bentuk spektrum *vowel*. Gaussian memakai jarak Mahalanobis dengan *full covariance*, sehingga arah fitur yang variansnya kecil pada data latih diberi bobot sangat besar. *Speaker* baru yang sedikit bergeser pada arah tersebut langsung mendapat NLL tinggi, terlihat dari selisih ke pesaing yang pada *open* hanya tersisa 20% pada Gaussian dibanding 45% pada DTW.
- Jumlah parameter dibanding jumlah data, di mana Gaussian *full covariance* memiliki 819 parameter per *vowel* dari enam rekaman. Model ini sangat pas untuk data latihnya (*closed recordings* 100,00%), tetapi sudah turun pada rekaman kedua *speaker* yang sama. *Averaged template* DTW tidak memperkirakan sebaran, sehingga lebih sulit *overfit* dan akurasinya sama pada kedua skenario *closed*.

DTW juga memperhatikan urutan *frame*, sedangkan Gaussian menganggap setiap *frame* independen. Untuk *vowel* tunggal yang hampir stasioner, menurut kami pengaruhnya kecil, dan eksperimen ini belum dapat memisahkannya dari dua penyebab di atas. Gaussian tetap unggul ketika data uji sangat mirip dengan data latih, seperti pada *closed recordings* (100,00%), dan pada *vowel* /o/ di *open speakers* (93,75% dibanding 81,25%), walaupun angka /o/ ini sebagian berasal dari perannya sebagai penampung kesalahan.

5.8 Mengapa Akurasi Closed dan Open Scenario Dapat Berbeda?

Perbedaan akurasi berasal dari seberapa mirip data uji dengan data yang dipakai untuk membangun *template* atau model. Pada *closed recordings*, data uji adalah data latih itu sendiri, sehingga akurasinya menjadi batas atas. Pada *closed speakers*, speakernya sama, sehingga saluran suara, *pitch*, logat, mikrofon, dan ruangan juga sama, dan yang berbeda hanya variasi pengucapan antar rekaman. Pada *open speakers*, terdapat tiga sumber perbedaan sebagai berikut.

1. Variasi antar *speaker*, yaitu panjang dan bentuk saluran suara menggeser *formant*, ditambah perbedaan *pitch*, logat, dan cara mengucapkan *vowel* seperti /e/.
2. Variasi kanal dan lingkungan**,** di mana rekaman *open* dibuat kelompok lain dengan perangkat, ruangan, *noise*, *gain*, dan jarak mikrofon yang berbeda.
3. Cakupan data latih yang terbatas, karena *Template* dan model hanya belajar dari enam *speaker*, sehingga variasi yang dianggap wajar tidak mencakup semua jenis suara.

Hasil eksperimen konsisten dengan penjelasan ini pada kedua sistem. Akurasi DTW turun dari 96,67% pada *closed speakers* menjadi 82,50% pada *open*, dan Gaussian turun dari 93,33% menjadi 68,75%. Skor kelas benar ikut memburuk secara bertahap, dengan *cost* DTW naik dari 4,45 ke 5,28 lalu 7,42, dan NLL Gaussian naik dari 11,47 ke 20,53 lalu 52,04. Artinya, *frame* dari *speaker* baru berada jauh dari semua *template* dan model sekaligus. Penurunan Gaussian lebih besar karena *full covariance* lebih sensitif terhadap pergeseran fitur, seperti dibahas pada subbab 5.7.

6. Kesimpulan

Berdasarkan hasil eksperimen dan analisis, kesimpulan yang kami peroleh adalah sebagai berikut.

- DTW dengan *averaged template* memperoleh rata-rata akurasi lebih tinggi, yaitu 91,94% dibanding 87,36% pada Model Gaussian. Seluruh selisih ini berasal dari *open speakers* (82,50% dibanding 68,75%), karena rata-rata dua skenario *closed* kedua sistem sama.
- Pada *closed scenario* kedua sistem setara. Gaussian mencapai 100,00% pada *closed recordings* karena data ujinya sama dengan data pembentuk model, sedangkan DTW lebih stabil pada *closed speakers* (96,67% dibanding 93,33%).
- Penurunan akurasi dari *closed* ke *open* terutama disebabkan oleh perbedaan *speaker* dan kondisi rekaman, terlihat dari naiknya skor kelas benar dan mengecilnya selisih ke kelas pesaing pada kedua sistem.
- *Averaged template* membuat DTW lebih stabil terhadap rekaman dan *speaker* baru, walaupun akurasi *closed recordings*-nya tidak mencapai 100%.
- Kesalahan terbanyak pada kedua sistem adalah /u/ yang dikenali sebagai /o/, karena keduanya *vowel* belakang bulat dengan spektrum yang berdekatan. *Vowel* /e/ juga rawan tertukar dengan *vowel* tetangganya.

7. Saran

Beberapa saran untuk pengembangan sistem selanjutnya adalah sebagai berikut.

- Menambah jumlah dan keragaman *speaker* latih, karena rentang *pitch* dan perangkat rekam yang lebih luas akan membuat *template* dan model lebih mewakili, terutama untuk *speaker* dengan F0 tinggi.
- Menerapkan normalisasi fitur dengan data validasi. Eksperimen tambahan menunjukkan CMVN dapat mengurangi pengaruh ciri *speaker* pada Gaussian. Pemilihan konfigurasinya sebaiknya memakai data validasi, misalnya *leave-one-speaker-out*, agar tidak bergantung pada data *open*.
- Mencoba model yang lebih fleksibel, seperti Gaussian dengan *diagonal covariance* atau *Gaussian Mixture Model*, serta beberapa *template* per *vowel* pada DTW, dapat menangkap variasi suara dengan lebih baik.
- Menyamakan protokol rekaman antar kelompok, di mana perangkat, jarak mikrofon, dan durasi *vowel* yang seragam akan mengurangi variasi kanal, sehingga hasil *open* lebih mencerminkan perbedaan *speaker*.

8. Pembagian Tugas

Pembagian tugas anggota kelompok dapat dilihat pada tabel berikut. Selain tugas tersebut, setiap anggota juga merekam 10 audio sebagai data *closed*.

Nama	NIM	Tugas
Aliya Husna Fayyaza	13523062	Preprocessing dan data loading
Muhammad Timur Kanigara	13523055	Ekstraksi MFCC 39 dimensi
Raka Daffa Iftikhaar	13523018	Sistem 1 DTW dan perhitungan akurasi
Farrel Athalla Putra	13523118	Sistem 2 Model Gaussian dan perhitungan akurasi
Kefas Kurnia Jonathan	13523113	Laporan
Muhammad Fithra Rizki	13523049	Slide presentasi

Tabel 8. Pembagian tugas anggota kelompok